

Thuật toán Passive Aggressive Regressor cho bài toán tối ưu hóa mô hình dự đoán chiến lược truyền thông Instagram

Nhóm 12

Trường Đại học Khoa học Tự nhiên, ĐHQGHN

Chuyên ngành: Khoa học dữ liệu

Giảng viên: Hoàng Nam Dũng

Ngày 26 tháng 9 năm 2026

Thành viên trong nhóm

Mã học viên	Họ và tên
25007892	Tạ Quang Tùng
25007898	Đoàn Đức Tài
25007858	Phạm Duy Phương

Thuật toán Passive Aggressive Regressor

- 1 Giới thiệu bài toán và bộ dữ liệu
- 2 Mô hình hồi quy tuyến tính cơ bản
- 3 Mô hình hồi quy tuyến tính Online Learning
- 4 Thuật toán Passive Aggressive Regressor
- 5 Thực nghiệm

Chương 1

Giới thiệu bài toán và bộ dữ liệu

1. Giới thiệu bài toán Instagram Reaching:



Hình 1: Ứng dụng phổ biến của Instagram

2. Giới thiệu về bộ dữ liệu:

- Dữ liệu Fashionista's Instagram cá nhân do Aman Kharwal sử dụng và công bố trong bài viết “Instagram Reach Analysis using Python” đăng ngày 22/03/2022.
- Bộ dữ liệu có khoảng hơn 20000 điểm dữ liệu và 13 trường thông tin khác nhau.

=> Mục tiêu: dự đoán tổng lượt Impressions của bài đăng Instagram dựa trên các chỉ số tương tác đầu vào (Likes, Saves, Comments, Shares, Follows, Profile Visits, ...).

Chương 2

Mô hình hồi quy tuyến tính cơ bản

1. Mô hình Linear Regression:

- **Linear Regression** (Hồi quy tuyến tính) là một thuật toán học máy dùng để dự đoán một **giá trị liên tục**.

$$y = w^T x + b$$

- Ý tưởng: thu thập toàn bộ tập dữ liệu và tìm trọng số w sao cho tổng bình phương sai số đạt GTNN.

$$\min_w \sum_{i=1} (y_i - \hat{y}_i)^2$$

$$\text{với } w_i = (X^T X)^{-1} X^T y_i$$

=> Độ phức tạp thuật toán: $O(nd^2)$

2. Cải tiến mô hình hồi quy:

Hạn chế:

- Thường học trên toàn bộ tập dữ liệu (Batch Learning)
- Khi có dữ liệu mới thì mô hình phải huấn luyện lại toàn bộ
- Chi phí tính toán tăng khi số lượng mẫu lớn

Đề xuất cải tiến thuật toán:

- Dữ liệu xuất hiện liên tục theo thời gian
- Cập nhật mô hình nhanh khi có dữ liệu mới
- Không muốn lưu và huấn luyện lại toàn bộ dữ liệu
- Tiết kiệm tài nguyên tính toán

Chương 3

Mô hình hồi quy tuyến tính Online Learning

1. Mô hình hồi quy tuyến tính Online Learning:


- Online Linear Regression là cách xây dựng mô hình tuyến tính theo kiểu học tuần tự, nhằm tính toán sai số rồi cập nhật trọng số ngay lập tức thay vì huấn luyện toàn bộ mô hình ngay từ đầu.

$$y_t = w_t^T x_t + b$$

- Ý tưởng: (tại mỗi điểm dữ liệu)
 - Nếu sai số dự đoán $\leq \epsilon$ thì không cập nhật trọng số w
 - Ngược lại sẽ cập nhật trọng số w

=> Độ phức tạp thuật toán: $O(d)$

2. Minh họa ý tưởng Online Learning:



Hình 2: Quy trình mô hình hồi quy tuyến tính trực tuyến

Chương 4

Thuật toán Passive Aggressive Regressor

1. Mô hình hóa bài toán Instagram Reaching:

Cho $x = [\text{Likes, Saves, Comments, Shares, ProfileVisits, Follows}]$ và $y = \text{Impressions}$ với n mẫu dữ liệu. Khi đó, ta có mô hình hóa sau:

$$\hat{y}_t = w_t^T x_t$$

trong đó:

- x_t là vector đặc trưng của mẫu thứ t ($x_t \in R^{d \times 1}$)
- y_t là giá trị thực tế ($y_t \in R$)
- $\hat{y}_t$ là giá trị dự đoán ($\hat{y}_t \in R$)
- w_t là vector trọng số tại thời điểm mẫu t ($w_t \in R^{1 \times d}$)

2. Cơ chế Passive và Aggressive của mô hình:

- Sai số $e_t = y_t - \hat{y}_t$
- Hàm mất mát:

$$L_t(w, x_t, y_t) = \max(0, |y_t - \hat{y}_t| - \epsilon)$$

- Nếu $|y_t - \hat{y}_t| \leq \epsilon$ thì $L_t = 0 \Rightarrow$ Không cần cập nhật trọng số (Passive)
- Nếu $|y_t - \hat{y}_t| > \epsilon$ thì $L_t > 0 \Rightarrow$ Cập nhật lại trọng số (Aggressive)

3. Cập nhật trọng số (Aggressive):

- Cập nhật vector trọng số với siêu tham số $C > 0$:

$$w_{t+1} = \min_w \frac{1}{2} \|w - w_t\|^2 + f(\zeta_t) \quad \forall L_t(w, x_t, y_t) \leq f(\zeta_t)$$

- Cập nhật hệ số:

Standard PA	PA-I (Linear Slack)	PA-II (Quadratic Slack)
$f(\zeta_t) = 0$ $\tau_t = \frac{L_t(w_t, x_t, y_t)}{\ x_t\ ^2}$	$f(\zeta_t) = C\zeta_t$ $\tau_t = \min(C, \frac{L_t(w_t, x_t, y_t)}{\ x_t\ _2^2})$	$f(\zeta_t) = \frac{\zeta_t^2}{2C}$ $\tau_t = \frac{L_t(w_t, x_t, y_t)}{\ x_t\ ^2 + \frac{1}{2C}}$

- Quy tắc cập nhật trọng số (bước cuối cùng):

$$w_{t+1} = w_t + \tau_t \cdot \text{sgn}(y_t - w_t^T x_t) x_t$$

Chương 5

Kết quả thực nghiệm

1. Thông số đánh giá:

- Coefficient of Determination:


$$R^2 Score = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2}$$

- Mean Square Error:


$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Kiểm chứng so sánh dựa trên số bước lặp và thời gian chạy chương trình.

2. Ảnh hưởng của tham số C với PA-I:




Hình 3: MSE theo số vòng lặp




Hình 4: MSE theo thời gian

3. Ảnh hưởng của tham số C với PA-II:




Hình 5: MSE theo số vòng lặp




Hình 6: MSE theo thời gian

4. So sánh các biến thể PA, PA-I, PA-II




Hình 7: MSE theo số vòng lặp




Hình 8: MSE theo thời gian


5. So sánh PAR với Regressions:



6. So sánh PAR với các thuật toán tối ưu khác:



Hình 9: MSE theo số vòng lặp




Hình 10: MSE theo thời gian

7. Kết quả đánh giá:

Model	R^2 Score	RMSE	Thời gian (ms)
Gradient Descent (GD)	0.889463	1654.703472	2200.26
Passive Aggressive (PAR)	0.877722	1740.367728	874.05
Nesterov	0.889456	1654.755890	3450.14

Bảng 1: So sánh hiệu năng các mô hình regression

8. PAR và PAR + RIDGE



THANKS FOR LISTENING